

**Szegedi Tudományegyetem
Informatikai Intézet**

**Automatikus magpontkiválasztás régió növelés-alapú
agytumor-szegmentáláshoz MRI-felvételeken**

Diplomamunka

Készítette:

Varga-Betlehem Ádám

programtervező
informatikus MSc szakos
hallgató

Témavezető:

Dr. Kardos Péter

adjunktus

Szeged
2025

Feladatkiírás

Az agy szöveteiből kiinduló daganatok korai felismerése kritikus fontosságú az eredményes kezelés végett. Az agytumorkok diagnosztizálásának legpontosabb képalkotó eljárása a mágneses rezonancia vizsgálat (MRI). A diplomamunka keretében a hallgatónak az alábbi feladatokat kell elvégeznie:

- Tanulmányozzon és valósítson meg a fellelhető irodalomban legalább két olyan különböző, régiónövelésen alapuló agytumor szegmentáló eljárást, amelyek a magpontokat automatikusan választják ki az MRI felvételeken!
- Konstruáljon meg egy saját automatikus régiónövelő eljárást is, vagy a vizsgált korábbi eljárásoknak dolgozza ki egy-egy módosított változatát!
- Készítsen egy grafikus felülettel rendelkező alkalmazást az MRI felvételek betöltésére, az algoritmusok tesztelésére és a szegmentált objektumok megjelenítésére!
- Végül többféle alkalmas mérőszám alapján hasonlítsa össze a korábbi eljárásokat a saját ill. a módosított algoritmusokkal!

Tartalmi összefoglaló

- ***A téma megnevezése:***

Automatikus magpontkiválasztáson alapuló régiónövelő eljárás implementálása és módosítása agytumor-szegmentáláshoz MRI-felvételeken

- ***A megadott feladat megfogalmazása:***

Automatikus magpontkiválasztást alkalmazó régiónövelő eljárások implementálása MRI agytumor felvételeken, valamint ezek módosítása. A szakirodalombeli és módosított eljárások eredményeinek összehasonlítása. Továbbá feladat egy grafikus felhasználói felület elkészítése a felvételek betöltésére, az algoritmusok futtatására és a szegmentált objektumok megjelenítésére.

- ***A megoldási mód:***

A különböző eljárások moduláris részekre lettek bontva és implementálva. Előfeldolgozásra, magpontkiválasztásra, magpont-szűrésre és régiónövelésre lettek szétbontva. Ezáltal könnyebben beilleszthetőek a grafikus felhasználói felületre, könnyebben bővíthetőek új módszerekkel, akár az adott algoritmusok is egy új lépéssel. Továbbá egyszerűbben tesztelhetőek, hibakereshetőek és könnyebben egymáshoz hasonlíthatóak a különböző eljárások eredményei.

- ***Alkalmazott eszközök, módszerek:***

Az algoritmusok megvalósítása Python nyelven történik, a képek kezelésére és feldolgozására különböző függvénykönyvtárak kerülnek alkalmazásra, többek között OpenCV, NumPy, NiBabel, SciPy, illetve a grafikus felhasználói felülethez PySide6 csomag. A nem felhasználói felületen történő ábrák megjelenítésért a Matplotlib pyplot modulja felel.

- ***Elért eredmények:***

A két eljárás implementálása és módosítása megtörtént. A grafikus felhasználói felületen ezen variációk futtathatóak és szegmentált eredményeik megtekinthetőek. A módszerek összehasonlítása különböző metrikák alapján történt. A módosított eljárások bizonyos esetekben pontosabb és stabilabb szegmentációs eredményt képesek adni az irodalmi megfelelőjükhöz képest.

- ***Kulcsszavak:***

agytumor, MRI, régiónövelés, divergencia, ROI, hisztogram, blokk, ablak, intenzitás

Tartalomjegyzék

FELADATKIÍRÁS.....	2
TARTALMI ÖSSZEFOGLALÓ	3
TARTALOMJEGYZÉK	4
BEVEZETÉS	6
1. ORVOSI KÉPFELDOLGOZÁS/KÉPALKOTÁS.....	7
1.1. Az MRI	8
1.2. Agytumor	8
2. SZEGMENTÁLÁS.....	10
3. BLOKK- ÉS INTENZITÁSALAPÚ MAGPONT-KIJELÖLÉS.....	11
3.1. Az alaplómódszer	11
3.2. A módosított módszer	12
4. DIVERGENCIAALAPÚ MAGPONT-KIVÁLASZTÁS	15
4.1. Az alaplómódszer	15
4.2. A módosított módszer	18
5. IMPLEMENTÁCIÓK	22
5.1. A Program megvalósítása.....	22
5.2. Blokk- és intenzitásalapú magpont-kijelölés megvalósítása	24
5.2.1. Az alaplómódszer implementációja	24
5.2.2. A módosított módszer implementációja.....	26
5.3. Divergenciaalapú magpont-kiválasztás megvalósítása	27
5.3.1. Az alaplómódszer implementációja	27
5.3.2. A módosított módszer implementációja.....	30
6. EREDMÉNYEK.....	34
6.1. Használt metrikák	34

6.2.	Blokk- és intenzitásalapú módszer és módosításának összehasonlítása	35
6.3.	Divergenciaalapú módszer és módosításának összehasonlítása	39
	ÖSSZEGZÉS.....	43
	IRODALOMJEGYZÉK	44
	NYILATKOZAT	46
	MELLÉKLET.....	47

Bevezetés

Az agydaganat, mint minden daganat súlyos betegségnek számít. A legagresszívabb daganatoknál hosszútávon a kezelések ellenére nagyon alacsony a túlélési esély [17]. Így a korai felismerés mellett, a diagnózis felállításához és a kezelés megtervezéséhez elengedhetetlen a daganat megtalálása és pontos körülhatárolása. Leggyakrabban az agy vizsgálatára mágneses rezonancia (MRI) képalkotást használnak, mivel ez az eljárás képes részletes és kontrasztgazdag képet adni a lágyyszövetekről. Bizonyos esetekben röntgen alapú CT-felvételeket is szokás használni, ami hozzáférhetőbb és gyorsabb, azonban kevésbé ad pontos információt a lágyyszövetekről.

Ezen felvételeket hozzáértő szakorvosok gyakran manuálisan értékelik ki, ami időigényessé teszi a folyamatot, illetve nagyban függ az adott szakorvos szakértelmétől és tapasztalatától a szegmentálás eredménye. Különböző vizsgálatok szerint [2] a szakértők által készített szegmentációk között is jelentős eltérés figyelhető meg, ami nagyban köszönhető a tumorok változatos megjelenéseinek.

Automatizált képfeldolgozó eljárások segíthetik az orvosok munkáját és csökkenthetik a kiértékelés idejét. A régiónövelés-alapú szegmentálás a digitális képfeldolgozás egyik klasszikus módszere, amely egyszerű működési elven alapul. A módszer sikeressége, nagyban függ a kijelölt magpontoktól (seed point), amelyekből az eljárás indul.

A diplomamunkám célja a szakirodalomban ismertetett két automatikus magpontkiválasztást alkalmazó régiónövelés-alapú módszer implementálása, illetve ezen módszerek egy-egy módosított változatainak elkészítése. Továbbá feladat egy olyan felhasználói felület elkészítése, ahol a tumorról készült képet be lehet tölteni, és a kívánt módszerrel szegmentálást végezni, majd ezen szegmentált eredményt megtekinteni. Végezetül a módosított módszerek szegmentált eredményét hasonlítom össze az eredeti verzióval elért eredményekkel, alkalmas pontszámok alapján az egész adathalmazra.

1. Orvosi képfeldolgozás/képképzés

Az orvosi képképzés célja, hogy anatómiai vagy funkcionális információt szerezzünk a vizsgálandó területről anélkül, hogy egészségkárosító hatása lenne, vagy a diagnosztikus használat szemben elhanyagolható legyen az egészségkárosító hatás [18]. Különböző képképző eljárások különböző információval szolgálnak.

A számítógépes tomográfia (CT, Computed Tomography) röntgensugárral dolgozik, ezek áthaladnak a testen, amit különböző szervek, szövetek különböző mértékben nyelnek el, ezzel információt adva a test belső felépítéséről, elsősorban a csontrendszer felépítéséről. A CT tipikus skálája a Hounsfield-skála, amin a lágy szövetek nagy mértékben egybeesnek, ezért a CT vizsgálatoknál szokás még kontrasztanyagot is használni a vizsgált terület kiemelésére [18]. A csontsérülések mellett használható érrendszeri betegségek, gyulladások, daganatok, belső vérzések, idegrendszeri betegségek diagnosztizálására is, emellett relatív gyorsan végezhető vizsgálat, viszont sugárterheléssel jár [19].

Funkcionális képeket készítenek például a pozitronemissziós tomográfia (PET, Positron Emission Tomography) technikával, aminek alapja, hogy bizonyos radioaktív anyagok bomlásakor pozitronok keletkeznek. Ezen pozitronok fokozatosan lelassulnak a közegben, majd elektronnal ütközve megsemmisülnek, ekkor két ellentétes irányba távozó gamma-foton keletkezik, aminek egyidejű érzékelése adja a vizsgálat alapját [18]. Lényegében a pozitronbocsátó izotópok testbeli eloszlását szeretnék megállapítani, például felhalmozódik rákos sejtekben ez az anyag, vagy más energiaigényes sejtekben. Gyakran CT-vel együtt használják, úgynevezett PET-CT gépek, így anatómiai információt is kapnak a funkcionális mellé. A fő fókuszban az anyagcsere van, jellemzően rákdiagnosztika, Alzheimer-kór, szívizom, agyműködés vizsgálatára használják [18].

Hasonló elven alapuló módszer az egyfoton-emissziós komputertomográfia (SPECT, Single-Photon Emission Computed Tomography), ahol a radiofarmakon eloszlását vizsgálják. A radiofarmakon radioaktív anyag, amely a szervezetben bomlása során gamma sugárzást bocsát ki, amit rögzítenek [18]. A fő fókusz a véráramlás. Alkalmazzák a szívizom vérellátása, csontbetegségek, pajzsmirigy vizsgálatára, alkalmas lehet tumor kimutatására is, ha olyan radiofarmakont használnak, ami a tumorban dúsul, emellett az agyi funkciók vizsgálatára is alkalmas. A SPECT szélesebb körben elérhetőbb és olcsóbb, viszont alacsonyabb felbontásra és kontrasztra képes, mint a PET [18].


1.1. Az MRI

A mágneses rezonancia képalkotás (MRI), azon alapul, hogy egy atommag spinjének erős mágneses térben két állapota van. Párhuzamos, ami az alacsony energia szintű állapot, és az antipárhuzamos, ami a magas, és megfelelő hullámhosszúságú rádióhullámokkal az alacsonyból a magasabbra vihető, ez a gerjesztési folyamat. Utána elindul a relaxációs folyamat, amiben a spinek visszatérnek nyugalmi, azaz az alacsony energiaszintű állapotukba, miközben rádiósugárzást bocsátanak ki [18]. Ezt a folyamatot többször ismétlik T_R időnként a jel-zaj viszony javítása érdekében, végül ennek a sugárzásnak az erősségének és időbeni változásának mérésével kapják a képet. A mérésekre különböző impulzusszekvenciákat használnak, amelyek közül a leggyakoribb a spin-echo szekvencia. Ezen esetben egy először 90° , majd 180° -os impulzust használnak. A T_1 a longitudinális, míg a T_2 a transzverzális relaxációs idő. Mindkettő a térrész fizikai és kémiai tulajdonságától függ, és a T_2 jóval rövidebb ideg tart, mint T_1 . Egy szekvencián belül a kezdő 90° -os impulzus és a maximális jel között eltelt időt T_E jelöli [18]. A T_R és T_E különböző megválasztásával különböző súlyozású képeket lehet kapni. A T_1 -súlyozott kép úgy készül, hogy a T_R és T_E rövid. A T_R rövidsége miatt a T_1 -nek nincs ideje visszaállni, míg a T_E rövidsége miatt a T_2 -különbségek nem tudnak érvényesülni. T_2 -súlyozott képet úgy kapni, hogy a T_R és T_E is hosszú. A T_R hosszúsága miatt nincs jelentős különbség a T_1 -relaxációban az egyes szövetek között, míg a T_E hosszúsága miatt a T_2 -relaxációban lesznek jelentősebb különbségek. A FLAIR (Fluid-Attenuated Inversion Recovery) kép inverziós szekvenciával készült T_2 -súlyozott kép, ahol a folyadék nem ad jelet, mert az első impulzus után addig várnak, amíg a folyadék mágnesezettsége nulla lesz és utána adják ki a következő impulzust. [18]

1.2. Agytumor

Az agyban létrejövő kóros sejtszaporulatot agydaganatnak nevezik [14]. Egy agydaganat lehet elsődleges vagy másodlagos. Az elsődleges daganatok elsősorban az agyban képződnek vagy a közeli szövetekben. Az alapján csoportosítják őket, hogy honnan erednek, például idegsejtekből gliómának, agyhártyából meningeomának hívják [13]. Az agy más területeire áttétet képezhetnek, de más testrészekre általában nem szoktak terjedni. A másodlagos vagy másnéven áttétes tumor, a test egy másik pontjáról például tüdő, mell, vese terjed át az agyra. Egy elsődleges tumor lehet jó- vagy rosszindulatú, míg másodlagos csak rosszindulatú lehet. A rosszindulatú agydaganat gyorsabban nő, mint a jóindulatú, és behatol a környező agyszövetekbe elpusztítva azt. Ezzel

szemben a jóindulatú általában jól körülhatárolt, könnyebben eltávolítható lehet, és ritkábban újul ki, így a sebészi beavatkozás megoldást jelenthet [12]. Gyakran legelőször CT képet készítenek a diagnózis felállításakor, ami relatíve gyorsabb és elérhetőbb, mint MRI, emellett jól tud detektálni még vért, viszont a koponya a röntgensugarak nagyrésztét felfogja. Szinte mindig készül MRI kép is, mert jóval részletesebb képet ad lágyszövetekről, viszont sokkal lassabb és nem jár röntgensugárzással. Az elkészült képeken az orvosok különböző elváltozásokat keresnek, például a középvonal eltolódását, sötétebb, világosabb foltokat [11]. Az 1.1. ábrán jól látszik a CT és MRI minősége közötti különbség, és a bal oldalon levő CT kép a középvonal eltolódására jó példa, míg a középső a FLAIR kép, míg a jobboldalon levő egy kontrasztanyag használatával készült T₁ kép. Meglehet említeni, hogy a T₁ képek kontrasztanyag használatával jól használhatóak új elváltozások, míg T₂ és FLAIR képek pedig magas fokú gliómák és ödémák kimutatására [1]. Mivel a használt adathalmazom legfőképp gliómás daganatokat tartalmaz, ezért a FLAIR képeim fogok dolgozni.



1.1. ábra: Abnormális agyi CT, MRI FLAIR és T₁ [11]

2. Szegmentálás

A szegmentálás célja, hogy a képeket olyan részekre osszuk fel, amelyek megfelelnek a valós leképezett objektumoknak, területeknek [15]. Általában az előfeldolgozás után következik és megelőzi a jellemző kinyerést, ha a gépi látás moduláris rendszerének modelljében próbáljuk elhelyezni. Egy nehéz feladatról van szó, ami egyáltalán nem egyértelmű. Orvosi képeken a sebésznek tudnia kell mit kell eltávolítani, a radiológusnak tudnia kell melyik részt bombázzhatja sugarakkal, de azt is tudnia kell mely részeket nem érheti sugárzás. A szegmentálás bonyolultságából adódóan számos módszert kifejlesztettek, köztük küszöbölés, él-alapú, régió-alapú, illesztésen alapuló szegmentáló módszereket, hogy pár alap-módszert említsek. Az (1.1) képletben a szegmentálás van leírva formálisan [15], ahol az R a teljes képet, R_i az i -edik régiót, a P a homogenitási kritériumot és n a régiók számát jelöli, emellett minden régió önmagával egybefüggő.

$$\bigcup_{i=1}^n R_i = R, \quad R_i \cap R_j = \emptyset, \quad P(R_i) = 1, \quad P(R_i \cup R_j) = 0 \quad (1.1)$$

A formális leírás annyit jelent, hogy a régiók egyesítése visszaadja a teljes képet, minden régió diszkrét, minden régióra teljesül a homogenitási kritérium, és bármely 2 régióra már nem. A küszöbölésnek az alapgondolata az, hogy az adott régióra tudunk mondani egy intenzitás értéket, küszöböt, ami felett vagy alatt minden érték az adott szegmenshez tartozik. Sokféle küszöb választási stratégia létezik, talán a legismertebb példa erre az Otsu módszere, ami olyan küszöbértéket keres, amire minimális az osztályon belüli variancia, ezzel megpróbálva elválasztani a háttérrel az előtérrel [15]. A régió-alapú szegmentálás az objektum által elfoglalt területet határozza meg. Ilyen módszer a régió növelés, ahol első lépésként kiválasztanak egy pontot vagy egy biztosan összetartozó pontokból álló kezdeti régiót. Minden lépésben megvizsgálják az aktuális régióval határos pontokat, majd hozzáadják azokat a régióhoz, amik kielégítik az adott hasonlósági kritériumot. Az algoritmus megáll, ha már nem tud több pontot hozzáadni a régióhoz [15]. Ebből is látszik, hogy létfontosságú a magpontkiválasztás, ami nagyban feladatfüggő. Ebbe a kategóriába eső más módszer még a szétválasztás és egyesítés, ahol az egyesítés különböző régiókat von össze egy kritérium alapján, míg a szétválasztás esetén a régiók nem elégítik ki a feltételt. Rendszerint a képet, régiót négy egyenlő részre osztják szét, amit egy hierarchikus négyes fa adatstruktúrában tárolnak, ahol minden csúcspont a négy feldarabolt részére mutat [15].

3. Blokk- és intenzitásalapú magpont-kijelölés

Ebben a fejezetben először Biratu és munkatársai [1] által javasolt módszert ismertetem, majd az általam végrehajtott módosítások kerülnek bemutatásra.


3.1. Az alapmódszer

Biratu és társai FLAIR képekre javasoltak algoritmust, mivel ezeken a képeken lehet a leghatékonyabban felismerni a gliómákat, amik a rosszindulatú daganatos megbetegedések legalább 80%-t teszik ki felnőttek esetén [1]. Továbbá a Brain Tumor Segmentation 2015 challenge (BraTS2015) közzétett adathalmazt használják, ami multimodális MR képeket tartalmaz gliómás daganatokról. Kihangsúlyozzák, hogy az előfeldolgozás, mint például a simítás, normalizálás és szükségtelen részek eltávolítása az nagyon fontos a nyers MRI képeken és a használt adathalmazon a nem kívánt részek már elvannak távolítva. Ajánlanak egy előfeldolgozási lépést a koponya eltávolítást, aminek a lényege, hogy mindent, ami nem agyi szövet eltávolítanak. Megemlítik, hogy ez egy nehéz, de szükséges feladat, amire számos megoldás létezik, ennek ellenére ajánlanak egy morfológián és küszöbölésen alapuló módszert.

```
func KoponyaEltávolítás(kép):  
    küszöb = Otsu(kép)  
    maszk = küszöbölés(kép, küszöb)  
    maszk = Nyitás(maszk)  
    maszk = Dilatáció(maszk)  
    maszk = LegnagyobbObjektum(maszk)  
    maszk = Zárás(maszk)  
    maszk = Lyukfeltöltés(maszk)  
    kép = Maszkolás(kép, maszk)  
    return kép
```

3.1 kódrészlet: Koponya eltávolítás pszeudokód [1]

A 3.1 kódrészleten láthatóan, először elvégeznek egy Otsu küszöbölést, majd a kapott maszkon egy morfológiai nyitást és dilataciót. A nyitással megszabadulnak a kisebb leszakadozó részekről, majd a dilataciós lépés alkalmazásával megpróbálják elérni, hogy a ténylegesen összefüggő részek összeérjenek. Ezután kiválasztják a legnagyobb összefüggő objektumot, ezzel feltételezve, hogy az az agy. Majd ezen a bináris objektumon elvégeznek egy morfológiai zárást, hogy a kisebb szétszakadásokat és lyukakat feltöltse, végül a nagy lyukakat is feltöltik. Az eredeti képből a maszk által jelölt részt tartja meg.



3.1. ábra: Példa koponyaeltávolításra. Eredeti kép forrása [1]


Érdeemes megjegyezni, hogy ez a módszer nem feltétlenül csak az agy körüli részt tünteti el, hanem ha minimális méretű a háttér és az agynak vannak sötétebb részei a perem mentén, akkor képes ezeket a részeket is háttérnek kezelni az Otsu módszerből adódóan, viszont ez a módszer szempontjából nem okoz problémát, hiszen a tumort megtartja, és az általam használt adathalmazban a háttér elég nagy területet foglal el. Az általuk felhozott példában (3.1 ábra) a háttér minimális volt, ahol ez megtörtént, mert ott túl is lógott a kép szélein a koponya. A többi felhozott példájukban, ahol a háttér körbe ölelte a koponyát, ott megfelelően működött a módszer. A mellékletben található M.1. és M.2. ábrán minden lépése végig követhető a módszernek.

A következő lépésre továbbfejlesztett régiónövelő (enhanced region growing) eljárásról hivatkoznak [1]. A már előfeldolgozott képet 8x8-as blokkokra osztja fel az eljárás, majd kiválasztja a legjobb öt, olyan régiót, ahol a legmagasabb az átlagintenzitás, hiszen FLAIR képeken a tumor intenzitás nagyobb, mint a környező szöveteké. Majd ezen régiók középpontját választja meg magpontnak. A régiónövelés egy standard változatát használják, ahol az intenzitás küszöbértéke 0.1, mert állításuk szerint az ő adathalmazukban a legtöbb tumor homogénnek tűnik, kiegészítő műveletnek, ha nem volt homogén, akkor a lyukakat kitölti a maszkban. A különböző kiindulási pontokból öt darab maszk áll elő, amit ROI-nak (Region of Interest) hívnak, ami a vizsgálni kívánt területet jelöli. Majd ezeket összeveti az adathalmazban található valós szegmentált tumorról különböző metrikák alapján, és a legjobbat fogja választani, mint szegmentált terület a kiértékeléshez.

3.2. A módosított módszer

Feltételezhető, hogy egy kezdőpont hibás lehet. Nem véletlenül van szükség többre, hiszen a tumor kicsi is lehet, és olyan módon foglalhatja el a 8x8-as blokkot, hogy a blokk középpont nem része. Például a tumor határvonalakra esik, így az intenzitás átlag elmosódik és a magpont kívül eshet a

tumoron. Az általam javasolt módszer az mozgóablak (Sliding Window) technika, amivel lehetne orvosolni az előbb említett problémákat. Finomabb mintavételezést eredményezne, tehát a legfényesebb régiók nagyobb valószínűséggel esnek a blokk középpontba, és csökken az esélye annak, hogy tumoron kívüli pontot választana a módszer magpontnak. Minden ablakban továbbra is számítható lenne az átlagintenzitás, vagy akár több különböző statisztika is, mint például intenzitás maximum vagy akár szórás. Mivel a szórás úgy van definiálva, hogy az átlagtól való átlagos eltérés, így első gondolatként az adott ablak globális átlagától való eltérését vizsgáltam, ami ugyanolyan tendenciát mutatott, mint az átlag szerinti pontozás, ezért új ötletként csak a lokális ablakon belüli szórást vizsgáltam. Ha a szórás az ablakban alacsony, akkor homogén területen helyezkedik el, ami önmagában nem elég, viszont súlyozhatom az ablak intenzitás átlagával, kiemelve a magasabb intenzitású homogénebb területeket. A következő gondolatként meglehet nézni mennyire folt vagy paca (blob) szerű, amire gyakran a Gauss szűrő második deriváltját használják fel (LoG: Laplacian of Gaussian) [20]. A foltok detektálása költséges, és a gyakorlatban az ablak jóval kisebb, mint maga a tumor. A LoG operátor önmagában egyszerű és konvolúcióval használható. A művelet duplán detektál éleket, ahogyan sötétebb területről világosabbra lép, először pozitív(világosabb), majd negatív(sötétebb) értékeket vesz fel, ahol nincs változás ott 0 marad. Az adathalmaz képein nincs tökéletesen homogén fehér terület, és a tumor belsejébe a gyakorlatban negatív és 0-hoz közeli értékek kerülnek, így a tumoron kívül a háttér és az agy határán ad hasonlóan alacsony értéket. Az agy többi részén, pedig magasabb értékeket ad, mint a tumornál és környékén. Tehát az ablakon belüli átlagot feltudom használni, viszont most is csak az ablak átlagintenzitásával súlyozva. A 3.2. ábra megmutatja a szórásból és LoG operátor segítségével számolt ponttérképet, ahol minden pixel az adott ablak középpontját jelenti, illetve az agy körvonala látható még az egyszerűbb vizualizáció céljából. (Az eredeti agykép a 4.1 ábrán szerepel először.)



3.2. ábra: BraTS20_Training_355_flair.nii 84-es rétegének szórás (bal) és LoG (jobb) ponttérképe

Az ablakok középpontja helyett lehetne választani a blokk maximum intenzitású pixelét, mint magpont. Nem-maximális elnyomás (NMS: Non-Maximum Suppression) technikával el lehet kerülni azt a nemkívánatos hatást, hogy az egymáshoz túl közel eső ablakok közül a közvetlenül egymás mellett lévő, illetve ugyanazon magponthoz tartozó ablakokat válasszon ki.


4. Divergenciaalapú magpont-kiválasztás

Ebben a fejezetben először Saad és munkatársai [2,3] által javasolt módszert ismertetem, majd az általam végrehajtott módosítások kerülnek bemutatásra.

4.1. Az alaplómódszer

Saad és társai először a vizsgálni kívánt területet határozzák meg (Region of Interest, a továbbiakban ROI) [2], majd ezen a területen kijelölik a magpontokat, és egy saját régiónövelést alkalmaznak [3]. A felhasznált adathalmazról annyit lehet tudni, hogy úgynevezett Diffúzió súlyozott MRI (DWI: Diffusion-Weighted MRI) képeket használtak fel. Nagyobb az elváltozott terület kontrasztja a hagyományos T_1 , T_2 képekhez mérten. Ezzel a technikával azt mérik mennyire diffúz egy terület, ahol a magas diffúzió sötét (hypointense), míg az alacsony az világosabb (hyperintense) területként jelenik meg. A legérzékenyebb technikának tekintik, ha akut infarktust kell detektálni. Akut infarktus, vérzés (deoxihemoglobin), szolid tumor és tályog (fertőzés), amik világos hiperintenzív területként jelennek meg, míg krónikus infarktus és vérzés (oxihemoglobin) sötétebb hipointenzív területként jelenik meg [2]. Az adathalmazukban előfeldolgozás nélküli képek szerepelnek, így először 0-1 közé normalizálják az intenzitásértékeket, majd eltávolítják a háttérrel egyszerű küszöböléssel, amit tapasztalat útján állítottak be 0.023-ra. Ezután képesek végig követni az agy határvonalát és csak a benne levő részeket megtartani, ezzel hasonló eredményt kapnak, mint az általam használt adathalmazban szereplő FLAIR képek. Az általuk használt képeknek alacsony az intenzitása, ezért gamma korrekciót alkalmaznak.

A képjavító eljárások után következik a szétválasztás és egyesítés algoritmus, amely négyes-fa adatszerkezeten alapul. A hagyományosan vett értelemben a képből kiindulva azt rekurzívan négyfelé vágják mindaddig, amíg nem felel meg a homogenitási kritériumnak, majd a végére érve a szomszédos régiók, ha együttesen megfelelnek a homogenitási kritériumnak, akkor össze lesznek vonva [15]. A 4.1 ábrán látható egy példa a szétválasztás és egyesítés algoritmusra, az általam használt adathalmazon.




4.1. ábra: BraTS20_Training_355_flair.nii 84-es rétegen végrehajtott szétválasztás egyesítés

A cikkben [2] javasolt módszer abban tér el a hagyományos szétválasztás és egyesítés algoritmustól, hogy ha kell 4 részre vágja a képet, de legfeljebb csak a 3. szintig. A tényleges összevonás helyett pedig kiválasztja azon régiókat, amelyek tovább bonthatóak lennének, mivel a homogenitási kritérium úgy van megfogalmazva, hogy szerepel-e elváltozott terület a képen. A kritériumot minden iterációban hisztogram alapján fogják meghatározni az adott régióban. Az egész adathalmazból empirikusan megállapítottak egy hiperintenzív (0.47-0.8) és hipointenzív (0.1-0.25) tartományt, amiben a tumor előfordul. Ezt a tartományt a hisztogramból kiragadva számol átlagot, pixelek darabszámát, entrópiát és szórást, majd tapasztalati úton úgy dönt, hogy csak az átlagot és a tartományba eső pixelek darabszámát használja fel. A hiperintenzív tartomány küszöbértékét 0.495-re választja meg, tehát ami ennél magasabb, azt elváltozott területnek tekinti, ha ennél alacsonyabb, csak akkor fogja hozzátartozónak tekinteni, ha a tartományba eső pixelek száma meghaladja a 30-at. Természetesen az ellenkező irányban 0.2 átlagnál alacsonyabb, de nem 0 értékek vagy legalább 100 db tartományba eső pixel. Ezen küszöbértékeket szintén az adathalmazból fogja meghatározni.

A kapott területen fognak magpontot kijelölni úgy, hogy elkészítik a terület hisztogramját [3]. Aminek kiszámolják a divergenciáját ((4.1) képlet), és a maximális érték után eső, első 0-hoz legközelebbi értéket választja ki optimális küszöbértéknek, tehát az annál nagyobb intenzitásértékek magpontnak lesznek kiválasztva. A (4.1) képletben a $P(i)$ jelöli a hisztogramot, míg az előtte lévő hányados a deriváltját. Látszik, hogy a képlet nem egyértelmű és a cikkben se tárgyalják részletesebben. Ebből a képletből következhet, hogy csak a hisztogram deriváltját nézik, vagy annak szorzatát a hisztogrammal, esetleg a derivált szorzatát a normalizált hisztogrammal hiszen „P” betűvel jelölik, amivel valószínűséget szokás.

$$div(i) = \frac{dy}{dx}P(i) \quad (4.1)$$

Személy szerint a legutóbbi értelmezését használtam fel a képletnek. A hisztogram az intenzitáseloszlásokat mutatja, aminek a végén egy kisebb csúcs jelenik meg, mert a hiperintenzív terület sokkal világosabb. Ha a hisztogram deriváltját nézem, akkor megkapom milyen gyorsan változik az előfordulási gyakoriság az intenzitás mentén. A leggyakoribb intenzitásnál a legmagasabb a hisztogram értéke, miután lecseng a hisztogram és elérné a hiperintenzív régiót, újra nőni fog az érték, tehát egy lokális minimum helyen is áthaladt. Tehát a hisztogram deriváltjának maximuma a legmeredekebb változást mutatja, ahol a domináns szövetosztályból átlép egy másikba, és az azutáni 0 érték jelzi, hogy a változás kiegyenlítődik, határhoz ért. Ezt a deriváltat megszorozzák a normalizált hisztogrammal, tehát az intenzítások előfordulási valószínűségével. Ezzel megpróbálják figyelembe venni azt is, hogy mennyire jelentős az intenzitástartomány a képen belül. Tehát ha kicsi, akkor az egész tag gyenge, így képes lehet elnyomni a zajokat, ha nagy, akkor a változás megerősödik, ezzel kiemeli a lényeges struktúrákat. Végül minden magpont lesz, ami a küszöb felett helyezkedik el. Érződik, hogy ha túl kicsi a ROI, amin túlnyomó részt tumor szerepel, akkor nem fog tudni feltétlenül magpontot kiválasztani. Ha túl nagy a terület, amin kicsi elváltozás szerepel, akkor túl alacsony intenzitású pontokat fog választani, amik nem részei a tumornak.




4.2. ábra: A 4.1 ábrán jelölt terület hisztogramja és divergenciája

A 4.2 ábrán lehet látni a hisztogramot és a hozzátartozó divergencia képét, amit a 4.1 ábrán pirossal jelölt területen számolt az algoritmus. Az ábrán a zöld pont a maximumot jelöli, majd utána a piros pedig a küszöbértéknek választott intenzitást, ami fölött minden magpont.

A régiönövelés az egyik magpontból kezdődik. Amint befejeződik egy olyan magpont lesz választva, ami még nem tartozik egy szegmentált területhez sem, így a végeredmény egy maszk, amin akár több elkülönült régió is előfordulhat. A régiönövelés kritériumához felhasználják az előbb meghatározott optimális küszöbértéket. A régiönövelés leáll, ha az aktuális intenzitás eltérése a régió átlagától legalább akkora, mint a régió átlagának eltérése az optimális küszöbértéktől [3].

4.2. A módosított módszer

A hiperintenzív intervallum és az átlaghoz használt érték, amiket használnak azok fix küszöbértékek, amiket a cikkben [2] az adathalmaz alapján határoztak meg, ami pár kép volt. Érdekes lehet adaptívvá tenni ezt a küszöbértéket és a hozzátartozó átlagot, ezzel is rugalmasabbá téve az algoritmust, és pontosabbá téve a ROI kijelölést. Ha az agyi képen kellően nagy a kontraszt az agy és a tumor között, akkor a hisztogramon elkülönül a hiperintenzív régió a leggyakrabban előforduló intenzitástól. Ebben az esetben a globális maximum után lokális maximumot kell keresni. Ha találtam ilyet az azt jelenti, hogy van még egy gyakran előforduló elem, ami eltér az agyszövetről. Akkor azt tudom mondani, hogy megtaláltam a közepét a hiperintenzív tartománynak. A 4.3. ábrán jobb oldalon a zöld pont jelöli a megtalált maximumot, és a narancssárga vonal jelöli az eredeti, míg a kék a simított hisztogramot.




4.3. ábra: BraTS20_Training_355.flair.nii 78-as réteg Hisztogramja(bal) és nagyított változata(jobb)

A következő lépés a tartomány szélének a megtalálása. Ezt úgy érem el, hogy a globális és lokális maximum között keresem a legkisebb lokális minimum értéket. Feltéve, hogy találtam lokális maximumot, illetve minimumot (4.3. ábra kék pont). Ha veszem az átlagintenzitást ezen tartományon belül, az sokszor közel helyezkedik a lokális maximumhoz, viszont az egy kicsit túl szigorú a homogenitási kritériumként, ezért kicsit megengedőbb az a megközelítés, ha a hiperintenzív tartomány alsókorlátjának és a tartományon belüli átlagnak az átlagát választom, azaz

a kettő intenzitástól egyforma távolságra levő értéket (4.3.ábra jobb oldali piros pont). Természetesen ez nem mindig oldható meg, például ha túlságosan magas az ágy átlagintenzitása, akkor a 4.3. ábrán látott nagy csúcs egybeolvad az utána következő kicsivel megkülönböztethetlenné téve azt, ilyen esetben az alapértelmezett értékeket használom. A szétválasztás és egyesítés algoritmus cikkben [2] implementált verziója képes visszaadni nem összefüggő területeket, mint vizsgálni kívánt terület. Az általam használt adathalmazom, ezen különálló területek általában a koponya szélén lévő intenzív foltokként jelentkeznek, amik nem a tumor részei, inkább mérési hibának tűnnek, így egy utófeldolgozási lépésként, ezeket a leszakadozó területeket eltávolítom a vizsgálni kívánt területről. A magpont kiválasztást érdemes lehet finomítani, hiszen a divergencia zajos, a kiválasztás rajta emiatt sokszor pontatlan, illetve az adaptív hiperintenzív tartomány miatt megváltozhat a vizsgálni kívánt terület mérete, ezzel megváltoztatva a hisztogramot és divergenciát. A divergencián maximum, illetve minimum érték keresése helyett csúcsokat keresek, amihez első lépésben a hisztogramot simítom, hogy a zaj hatására keletkező csúcsokból kevesebbet találjak meg. A globális maximum helyett az eredeti módszer dupla átmenet, zaj vagy más okok hatására elnyomódhat, így szinte mindig a magasabb intenzitás felé eltolódva, ezért rangsorolom a megtalált csúcsokat a (4.2) képlet alapján.


$$score(i) = \alpha \frac{|i - g|}{N} + \beta \cdot \left(1 - \frac{div(i)}{div_{max}}\right) \quad (4.2)$$

A csúcsok magassága mellett figyelembe veszem azt is, hogy milyen messze van az eredeti teljes kép hisztogramjának globális maximumától, azaz a leggyakoribb képpont intenzitástól. A (4.2) képletben az alfa 0.7, illetve béta 0.3 tagok egyszerű súlyok. Az i a divergencián talált csúcs egy indexe, míg a g az előbb említett globális maximum indexe, melyeknek normalizált távolságát veszem, N a divergencia vektor hossza. A $div(i)$ jelöli a divergencia i -edik értékét, a div_{max} pedig a maximumát. Ebből a kettő tagból látszik, hogy nagyobb büntető pontot osztok az alapján minél távolabb van az eredeti kép leggyakoribb intenzitásától, illetve minél kisebb a csúcs a magassága. Lényegében azt a csúcsot keresem a divergencián a globális maximuma helyett, amelyik kellően magas érték és közelebb helyezkedik a teljes kép leggyakoribb intenzitásához (4.4 ábra).



4.4. ábra: BraTS20_Training_355_flair.nii 78-as réteg teljes kép histogram részlet(bal) és ROI divergencia részlet(jobb)

A 4.4 ábra a teljes kép histogramjának globális maximumát piros pont jelöli a bal oldalon, míg a jobb oldalon a vizsgálni kívánt terület divergenciáján a zöld pont a választott maximum csúcsot jelöli, ami nem a globális, viszont közelebb helyezkedik a bal oldalon jelölt globális maximumhoz, illetve a piros pont, ami az optimális küszöböt jelöli. A kiválasztott maximum csúcs után keresek egy 0-hoz kellően közel lévő átlagú ablakot, majd az ablak első elemét választom az optimális küszöbértéknek (4.4.ábra jobb oldal piros pont). A módszer következményeként két szélsőséges eset léphet fel, ahol az optimálisnak választott küszöb túl közel kerül a kiválasztott maximumhoz, ami önmagában akkor probléma, ha a kiválasztott maximum is nagyon magas intenzitáshoz tartozik, ami általában zaj eredménye. Illetve nem talál 0-hoz közeli értéket, vagy a divergencia legvégén a legmagasabb intenzitásoknál találja meg. Ha túl közel voltak egymáshoz, és magas intenzitáshoz tartoztak, akkor a választott maximum csúcsot és az utána következő értékeket eltávolítom, illetve ha az optimális küszöb tartozott nagyon magas intenzitásokhoz, akkor annak értékét csökkentem, hogy eltávolodjon a 0-tól. Ezután a módosított divergencián választok újra optimális küszöböt, ezzel szignifikánsan csökkentve az esélyt alulszegmentálásra. Végezetül továbbra is probléma, hogy ha túl nagy az algoritmus által kiválasztott terület, amin keresi a magpontokat, akkor túlságosan sokat fog találni, ami a tumor szélein lehet, vagy akár a tumoron kívül is az elég világos apró területeket. Utólag a magpontokból fogok eltávolítani elemeket.




4.5. ábra: BraTS20_Training_355_flair.nii 78-as réteg élkép(bal), megtartott élek dilatáltja(közép), eldobott ill. megtartott magpontok(jobb)

Sokszor zajra, apró foltokra hasonlítanak a tumoron kívül jelölt elemek, illetve nem szerencsés a tumor szélein is magpontokat jelölni, ezért veszem az agyról készült élképet (4.5. ábra), amin az erősebb éleket megtartom és binarizálom. Ezen bináris képen elvégzek egy dilatációt (4.5 ábra középső), mivel szeretném, hogy az tumoron kívül választott magpontok teljesen eltűnjenek, illetve a tumoron belül se legyen az élen és közvetlen közelében magpont. Ezért a magpontokból készítek egy bináris képet, és azon pontokat tartom meg rajta, ahol az élképen nincsen él. A 4.5 ábra jobboldali képén pirossal jelölve a törölt és zölddel jelölve a megtartott képpontok.

5. Implementációk


5.1. A Program megvalósítása

Az alkalmazás Python nyelven íródott. A felhasználói felület Pysied6 és matplotlib könyvtárral lett megvalósítva. A felületen lehet betölteni a képeket, kiválasztani a futtatni kívánt algoritmust, és módosítani a paramétereket. A számításokhoz numpy, opencv és egyéb könyvtárakat használtam fel. A program egy MR képet fog szegmentálni régió növelési algoritmussal, így lehetséges felbontani a feldolgozást diszkrét, moduláris lépésekre. Ennek a megvalósítása a feldolgozási lánc vagy csővezeték (pipeline) elv szerint történik, vagyis egymás után végrehajtott lépések sorozatával (5.1 ábra).



5.1. ábra: A feldolgozás lépései

Először az előfeldolgozási lépések futnak le, majd a magpont-kiválasztás, végül pedig a régió növesztés. Minden lépés ugyanazon a PipelineContext objektumon keresztül kommunikál egymással, amiben tárolom az eredeti képet, a különböző lépések eredményét és a felhasználó által beállított paramétereket. Mivel ezek a lépések különböző megvalósításokat követhetnek, így a megvalósításukra a stratégia tervezési mintát (strategy design pattern) használtam fel. Azaz minden lépés egy azonos interfészt valósít meg, így tetszőlegesen cserélhetők, anélkül, hogy a program bármelyik másik részéhez hozzá kelljen nyúlni. Az előfeldolgozási lépések a process(ctx), a magpont-kiválasztás a select(ctx), míg a régió növelés a run(ctx) metódust hívja, így a lépések nem egy interfészből származnak, így jól elkülönülve egymástól. A különböző algoritmusokat a gyártó minta (factory pattern) segítségével hoztam létre. A PipelineFactory osztály minden módszerhez, egy előre definiált csővezetékot épít fel, amit statikus függvényként lehet meghívni, így a felhasználói felületen elég kiválasztani melyik módszert szeretné a felhasználó futtatni. Minden csővezeték deklarálhatja, milyen vezérlőelemekre van szüksége ahhoz, hogy a lépések paramétereit a felhasználó beállíthassa. Ezen felsorolt elemek egy ControlPanel ösosztályból származnak, és csúszkák, számbeíró mezőket valósítanak meg. Ezen paneleket a ControlWindow osztály kezeli és jeleníti meg a felhasználó számára, amikor megváltoztatja az adott pipeline-t. Ez a megközelítés a kompozit (composite) és építő (builder) mintákat ötvözi.



5.2. ábra: A felhasználói felület

A felhasználói felület a Pyside6 függvénykönyvtárral készült, amit az 5.2 ábra mutat be. A felületen lehetőség van kép kiválasztására a „Choose Image” gombbal. Elsősorban „NifTi” (Neuroimaging Informatics Technology Initiative) fájlformátum feltöltésére van lehetőség, ami egy olyan nyílt formátum, amit leggyakrabban agyi és orvosi képalkotásban használnak [16], viszont hagyományos kép típust is fellehet tölteni. Lényegében a „NifTi” formátumú fájl egy képsorozat, jelen esetben az agyról, így a megjelenítésben egyszerre csak egy darab képet jelenít meg a program. A különböző rétegek között az egér görgőjével lehet váltani, ha a kurzor a kép felett van, ezen állítás az eredmény maszkokra is igaz, ha a módszer több darabot adna vissza. A képek felett van megjelenítve melyik réteg látszódik mennyiből. A bal oldali képen lehetőség van magpontok elhelyezésére és eltávolítására a bal, illetve a jobb egérgombbal, viszont ez csak a manuális módszer használja fel. Az 5.2 ábrán a képkiválasztó gomb alatt látható 3 legördülő listából balra az elsőt lehet kiválasztani a futtatni kívánt módszert. A középsőt lehet választani a „Release” és „Debug” mód között, ahol az előbbi a normál futtatást, míg az utóbbi a köztes lépések megjelenítését jelenti új ablakban, mint a 4.1 ábra. Végezetül a jobb oldalin a „Mask” és „Contour” opciók között lehet választani, ami az eredményt egy fekete alapon fehér maszkként, vagy az ábrán látható módon jeleníti meg. A megjelenített képek mellett jobb oldal található az aktuális módszerhez beállított vezérlőpanel, ahol az előre beégetett értékeket lehet változtatni. Végezetül az „Evaluate” gomb megnyomásával lehet futtatni a kiválasztott algoritmust az aktív rétegen a beállított paraméterekkel.

5.2. Blokk- és intenzitásalapú magpont-kijelölés megvalósítása

Ebben az alfejezetben a 3. fejezetben ismertetett eljárások implementációját fogom bemutatni.

5.2.1. Az alapszámítás implementációja

A programban való elhelyezéshez, el kell tudni helyezni a pipeline-ban (5.1. ábra). Az első lépés a koponya eltávolító függvény implementálása, ami egy előfeldolgozó lépés lesz, majd jön a maga a magpont kiválasztás és végül a standard régió növelés. A koponya eltávolítás a `SkullStripping` névre hallgató osztályban készült el, aminek belépési pontja a `process` nevű függvény. A cikkben [1] mellékelt pszeudokódban matlab beépített függvényhívásokat használnak. A legtöbb függvénynek van opencv könyvtárbeli megfelelője.

```
class SkullStripping:
    def process(ctx): #...
        cv2.threshold(img, 0, 255, cv2.THRESH_BINARY | cv2.THRESH_OTSU)
        #...
        se = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (2*r+1, 2*r+1))
        bw = cv2.morphologyEx(bw, cv2.MORPH_OPEN, se)
        #...
        return ctx
```

5.1 kódrészlet: Részlet a koponya eltávolítás

Az 5.1 kódrészlet példát hoz az opencv metódusok használatára, követve a 3.1 kódrészlet pszeudokódját. Az első lépés az Otsu küszöbölés volt, amit `cv2.threshold` nevű metódus megfelelő paraméterezésével valósítok meg, ami után a morfológiai nyitást és az összes morfológiai műveletet a `cv2.morphologyEx` függvény és annak megfelelő paraméterezésével érem el, jelen esetben a `cv2.MORPH_OPEN` paraméterrel, és egy lemezszerű strukturáló elemmel, amit a `cv2.getStructuringElement` nevű metódussal hozok létre. Következő lépés a dilatació, amit a `cv2.MORPH_DILATE` paraméterrel valósítható meg. A következő lépés már nem valósítható meg egy darab függvény hívással, ami a legnagyobb bináris objektum kiválasztása. Ebben az esetben egy egyszerű bináris címkézést alkalmazok, amit `cv2.connectedComponentsWithStats` nevű függvénnyel végzek el, ami visszaadja a címkézett képet és minden komponens statisztikáját, például a területet, ami alapján kiválasztom az objektumot. A legnagyobb objektumon elvégzett zárást egyértelműen a `cv2.MORPH_CLOSE` paraméterrel végzem el, majd következik a lyukfeltöltés [10], ami nincs megvalósítva opencv függvénykönyvtárban (5.2 kódrészlet). Az adott bináris képen egy darab objektum van, amiben

lehetnek lyukak, így elvégzek egy egyszerű régiónövelést a `cv2.floodFill` metódussal, ahol a magpont a háttér egy pontja lesz, például (0,0) koordináta. Először létre kell hozni egy üres maszkot, amiben majd írni fog ez a metódus, és a bejövő bináris maszkról készíteni egy másolatot, mivel módosítja a függvény, és az eredetijét még használok.

```
def fillHoles(self, bw):
    mask = np.zeros((bw.shape[0] + 2, bw.shape[1] + 2), dtype=np.uint8)
    inputMask = bw.copy().astype(np.uint8)
    cv2.floodFill(inputMask, mask, (0,0), 255)
    inputMaskInv = cv2.bitwise_not(inputMask)
    outImg = cv2.bitwise_or(bw.astype(np.uint8), inputMaskInv)
    return outImg
```

5.2 kódrészlet: Lyukfeltöltése egy objektumos bináris képen

A kapott maszkot invertálok a `cv2.bitwise_not` függvénnyel, így a háttér és az objektum fekete lesz és az objektumban lévő lyukak fehérek. Utolsó lépésként bitenkénti vagyolást végzek el a `cv2.bitwise_or` operációval az eredeti egy objektumos maszkon és az invertálás után kapott maszkon, tehát csak az objektum és azon belüli terület lesz fehér. Végül az eredeti képből csak a maszk által jelölt részt választom ki, és bele írom a `PipelineContext` objektumba, hogy a következő lépés használni tudja.

A következő lépés a magpont kijelölés, ami a `BlockBasedSeedSelector` nevű osztályba került, és a `select(ctx)` metódus a belépési pontja. Az adathalmazban 240x240 méretű képek vannak, míg a cikk által használtban 256x256 méretűek voltak. Mindkettő 8-cal osztható így nincs probléma, de azért elvégzek egy kép újra méretezést, hogy biztosan 8-cal osztható legyen, ha nem lett volna. Mivel a képek kis méretűek és minimális a számolás, így nem szükséges felbontani őket 8x8-as blokkokra, bőven elég két egymásba ágyazott ciklus, ami 8-asával lépeget. Minden iterációban az adott blokk középpontját és átlagát elmentem egy listába, majd a ciklus után kiválasztom az 5 legnagyobb átlagintenzitású blokk középpontját, beállítom őket a kontextusban a magpontoknak. A régiónövelést az `OpenCVRegionGrowing` osztály `run(ctx)` metódusa végzi. Kiolvassa a kontextusból a magpontokat, majd egy ciklusban mindegyikre elvégzem egy régiónövelést a `cv2.floodFill` metódussal. Mivel csak egész számokon értelmezett ez az algoritmus így a futtatás előtt a képet 0-255 közé normalizálom, és az intenzitás határ alapértelmezett értékét 75-re állítom be, amit a felhasználó, ha akar meg tud változtatni. Az

elkészült maszkokat egy listába gyűjtöm és elmentem a kontextusba. Ezután a felhasználói felület megjeleníti mind az 5 maszkot, amik között lehet lapozni.

5.2.2. A módosított módszer implementációja

Az általam javasolt módszer a mozgóablak technika, ahol nem 8x8-as méretű blokkokra osztom fel a képet, hanem egy fix méretű ablakot léptetek végig a képen és pontozom az összes ablakot, majd választom ki az N darab, alpból 5-nek beállított legjobb ablakot. Az ablakok létrehozását és sorba rendezését a `SlidingWindow` osztály valósítja meg, míg a magpont választást a `WindowSeedSelector`. Először egy generátor függvénnyel végig léptetem az ablakot a képen. Minden egyes ablakra kiszámolom a beállított módszer szerinti pontszámot (5.3. kódrészlet), alapértelmezetten az átlagintenzitást, majd a képpel megegyező méretű üres képre kiírom az ablakközéppontjának koordinátáiba, ezzel készítve egy ponttérképet (3.2 ábra).

```
def scoreWindow(self, window, mode):  
    #...  
    elif mode=="std":  
        score = -np.std(values) * 1-(np.mean(values))  
    elif mode=="blob":  
        LoG = gaussian_laplace(window, sigma)  
        score = -(LoG.mean()) * np.mean(values)  
    return score
```

5.3 kódrészlet: Részlet az ablak pontszámításból

Az átlagintenzitás és maximum intenzitás megtalálása, csak egy `np.mean` és `np.max` függvényhívás, viszont a másik két statisztika megtalálása trükkösebb. Az 5.3 kódrészlet kiemeli a szórás és LoG alapú pontozást. A ponttérképből a maximális értékek vannak felhasználva, és egyszerre mindig csak a vizsgált ablakot lehet látni. Ezzel szemben a szórás esetében, ahol az alacsonyabb érték a kedvezőbb (mivel a szórás pozitív, és minél kisebb, annál homogénebb az eloszlás), ezért veszem mínusz egyszeresét, majd súlyozom az átlaggal, pontosabban az (1-átlag)-gal, mert a 0-hoz közelebbi intenzitásértékeknél nem szeretném, ha magas lenne a pontszám. A másik kiemelt számolásnál is hasonló probléma merül fel. Először a `gaussian_laplace` elvégzi a konvolúciót a LoG operátorral, aminek veszem az átlagát negatív előjellel, így a 0-hoz közeli negatív értékek pozitívro fordulnak az eredetileg világosabb helyeken, így elég az ablak átlagával súlyozni.

```
def nonMaxSupression(self, scoreMap, size=3, th=0):
    localMax = maximum_filter(scoreMap, size=size) == scoreMap
    maxima = np.argwhere(localMax & (scoreMap>th))
    return maxima
```

5.4 kódrészlet: Nem-maximális elnyomás

A kész ponttérképen nem-maximális elnyomást (NMS) alkalmazok a `scipy.ndimage` csomag `maximum_filter` metódusával az 5.4 kódrészletben, ami a paraméterben megadott méretben tartja meg a maximumokat, pontosabban egy olyan mátrixot ad vissza, ahol az adott ablakban minden pozíción a megtalált maximum szerepel. Ezt összevetem az eredeti ponttérképpel és csak az adott mezőn megegyező értékeket tartom meg, ami után egy küszöböt használva eldobom a túl alacsony értékeket, például a 0-t. A megmaradt ablakok sorba rendezése és legjobb N db megtartása, így már kivitelezhető. A megtartott ablakokból a `WindowSeedSelector` osztály fog választani. Alapértelmezetten a középpontja lesz kiválasztva, mint magpont, de a felhasználónak opciója van beállítani az ablakban megtalált maximum értéket, mint magpont, ami előnyösebb lehet kevésbé homogén tumorok esetén. A régiónövelést ugyanúgy a `BlockBasedSeedSelector` osztály fogja végezni.

5.3. Divergenciaalapú magpont-kiválasztás megvalósítása

Ebben az alfejezetben a 4. fejezetben ismertetett eljárások implementációját fogom bemutatni.

5.3.1. Az alaplómódszer implementációja

Azon előfeldolgozó lépések, amelyek egy egyszerű függvény hívással megoldhatóak, mint a 0-1 közé normalizálás vagy a gamma korrekció, létrehoztam egy `PreprocessingStep` nevű osztályt, ami paraméterben egy függvényt vár és annak paramétereit, majd meghívja ezt a `process(ctx)` metódusával, hogy beilleszkedjen az előző fejezetekben tárgyalt csővezetékbe (5.1. ábra). A szétválasztás és egyesítés algoritmus a `SplitMerge` nevű osztállyal lett megvalósítva. A klasszikus megvalósítás négyfa adatstruktúrát használ, és ameddig homogenitási kritérium nem teljesül, addig rekurzívan a képet 4 részre bontja. Utána lentől felfele azok a szomszédos régiók, amelyek kielégítik a homogenitási kritériumot össze lesznek vonva [15]. Ha szegmentálásra használják fel, akkor általában minden csúcsa a fának egy régiót fog jelölni. A cikkben [2] tárgyalt homogenitási kritériumnál először kiszámolom a hisztogramot az adott régióra az `np.histogram` függvénnyel, ami visszaad 2 listát, ahol az egyik a megszámlolt értékek, a másik pedig az intenzitás értékek

határai, hogy milyen intenzitások kerültek egy osztályba a hisztogramon, majd ezt a két értéket fogom felhasználni a `getMeanSumIntensity` függvényben az 5.5 kódrészletben `hist` és `bin_edges` név alatt.

```
def getMeanSumIntensity(self, hist, bin_edges, intensityRange):
    low, high = intensityRange
    mask = (bin_edges[:-1] >= low) & (bin_edges[1:] >= high)
    bin_centers = (bin_edges[:-1] + bin_edges[1:]) / 2
    sum = np.sum(bin_centers[mask] * hist[mask])
    N = np.sum(hist[mask])
    avgHyper = 0
    if N != 0:
        avgHyper = sum / N
    return avgHyper, N
```

5.5 kódrészlet: Átlagintenzitás és pixel darabszám meghatározása a homogenitási kritériumhoz

Az 5.5 kódrészletben első lépésként meghatározom a maszkot a küszöbértékek és az előbbi intenzitás határok alapján, és ezen belül összeszámolom hány darab intenzitásérték van. A cikk [2] emellett még az intenzitás átlagot is számolja, bár a megadott képlet csak az előfordulási mennyiségeket átlagolja, de a kapott eredményeik az intenzitás átlagot használják fel, amit úgy lehet elérni, hogy az előfordulási mennyiségeket nem csak összeadni kell, hanem összeszorozni a hozzájuk tartozó intenzitásértékekkel, így kapva használható információt. Ezeket az intenzitásértékeket a `bin_centers` változó jelöli, mivel a `bin_edges` változó az osztályok határait jelöli, amikből több van, így a felső és alsó határ átlagát véve számolom ki az intervallum közepét. A választott homogenitási kritérium azt mondja meg, hogy előfordul-e elváltozott, hiperintenzív terület a vizsgált régióban. A szétválasztás `split` nevű függvény valósítja meg, ami rekurzívan 4 részre bontja a képet, ha nem homogén vagy nem érte el a 3. szintet. Ezután következne az összevonás, ami a szomszédos területeket összevonná, de erre nincs szükség, hiszen ugyanez a feltétele a végén a terület kiválasztásának, tehát az összevont területeket biztosan nem választanánk ki a végén. Így elég a 3. szinten megvizsgálni a szétbontási fázisban, hogy tovább bontható-e az adott régió, ha igen felvesszük egy listába. Az összevonás rész csak formális, amit a `merge` függvény valósít meg, ami a listában levő régiókból elkészít egy maszkot, és kivágja az eredeti képből ezt a részt, így megkapva a ROI-t.

A megkapott területből a `DivergenceSeedSelector` osztály fogja kiválasztani a magpontokat a `select(ctx)` metódusával.

```

def select(self, ctx):
    #...
    P = hist / np.sum(hist)
    div = np.gradient(hist) * P
    idx = np.argmax(div)
    tail = div[idx + 1:]
    nearest_zero = np.argmin(np.abs(tail))
    optimal_threshold_idx = nearest_zero + 1 + idx
    optimal_threshold = bin_edges[optimal_threshold_idx]
    #...
    return ctx

```

5.6 kódrészlet: Magpont kijelölés részlet

Az előző lépésben megkapott régiónak vesszem a hisztogramját, majd az `np.gradient` függvénnyel a deriváltját, amit beszorzok a normalizált hisztogrammal (5-6. kódrészlet). A kapott divergenciából `np.argmax` metódussal megkeresem a globális maximum helyét, majd az utána következő elemeken az `abs` és `argmin` függvényekkel a minimumhelyet, hogy megkapjam a globális maximum utáni, 0-hoz legközelebbi helyet, amit kiválasztok optimális küszöbértéknek. Végül pedig készítek egy üres maszkot, amin 1-re állítom azon pixeleket, ahol a vizsgált régió nagyobb az intenzitás érték, mint az optimális küszöb. Ezen koordinátákat kinyerem a maszkból az `np.argwhere` függvény segítségével, ami a sort, majd oszlopot adja vissza, ezért azt megfordítom, hogy oszlop és sor legyen, azaz (x,y) koordinátákkal tudjak dolgozni. Utolsó lépésként elmentem a kontextusba a magpontokat és az optimális küszöbértéket, amit későbbi lépésekben felhasználok.

A régiónövelést során először a magpontokat veszem sorra. Ha az adott pont már eleme az összesített maszknak, akkor kihagyom, egyébként elvégzek az adott pontra egy régiónövelést, majd az összesített maszkot frissítem a régiónövelés által adott maszkkal. Egy magpontra a `regionGrowing` függvény végzi el a műveletet, ami egy sor adatstruktúrával dolgozik, amibe a kezdőpontot teszem (5.7. kódrészlet).

```

def regionGrowing(self, image, seed, optimal_threshold):
    #...
    queue = deque([tuple(firstSeed)])
    while len(queue) > 0:
        x, y = queue.popleft()
        #...

```

```

        if np.abs(intensity - regionMean) >= np.abs(regionMean-optimal_threshold):
            continue
        segmented[y+dy, x+dx] = 1
    #...
    return segmented

```

5.7 kódrészlet: Régiónövelés részlet

Az 5.7. kódrészletben addig iterálok, amíg nem lesz üres a sor. Az első művelet a sorból a legrégebben rajta levő pont levétele, utána minden érvényes szomszédjára, ami nem lóg le a képről és még nem vizsgáltam, arra megnézem, hogy teljesül-e a homogenitási feltétel, azaz a régió átlagintenzitásától kisebb mértékben tér el a vizsgált pixel, mint az optimális küszöbérték és a régióátlag eltérése. Ha teljesül a feltétel hozzáveszem a maszkhoz a pontot és felírom a sorba. Miután egy magpontra befejeződik a régiónövelés, egy összesített maszkban 1-re állítom azon értékeket, ahol a visszaadott maszknak is volt értéke.

5.3.2. A módosított módszer implementációja

Az általam javasolt javítás első lépését az EnhancedSplitMerge osztály valósítja meg, aminek alapja az előbb tárgyalt SplitMerge osztály. Az hiperintenzív intervallum és a küszöbhoz használt átlag megtalálását a findHyperRangeAndAvg függvény végzi (5.8. kódrészlet).

```

def findHyperRangeAndAvg(self, image):
    #...
    peaks, _ = find_peaks(hist_s, prominence=0.2, width=5, height=0.3)
    valleys, _ = find_peaks(-hist_s)
    peaks_after = peaks[peaks>maxIdx]
    localMaxIdx = peaks_after[np.argmax(hist_s[peaks_after])]
    #...
    low = bin_centers[localMinIdx]
    #...
    avgHyper = (low + avgHyper) / 2
    return low, high, avgHyper

```

5.8. kódrészlet: Hiperintenzív intervallum és átlag meghatározás részlet

Az 5.8. kódrészletben található függvény bemenetele a vizsgált kép, aminek először elkészítem a hisztogramját az np.histogram függvénnyel, mivel a kapott eredmény elég zajos így alkalmazok rajta egy Gauss simítást a scipy.ndimage csomag gaussian_filter1d metódusával. A simított hisztogramon az np.argmax függvénnyel megkeresem a globális maximumot, majd a scipy.signal

függvénykönyvtár `find_peaks` módszerével keresek lokális maximumokat rajta, illetve lokális minimumokat a negatív előjeles változatán. Minden olyan talált lokális maximumot tartok meg ami a globális maximum után található, majd megkeresem közülük a legnagyobb értékűt a hisztogramon, illetve ugyanezt elvégzem a minimumokra is, viszont ott majd a minimum értéket keresem. Végezetül az így kapott indexek alapján meghatározom az alsó és felső intenzitást korlátot, és az 5.5. kódrészlethez hasonlóan átlagot számolok. A küszöböt a kapott átlag és az intervallum alsó határa közé félúton választom, ezzel megengedőbbé téve azt, mint maga az átlag. A szétválasztás és egyesítés által visszaadott területen a leszakadozó részeket a `filterDisconnectedROIs()` függvény távolítja el az (5.9 kódrészlet).

```
def filterDisconnectedROIs(self):
    #...
    numLabels, labels, stats, _ = cv2.connectedComponentsWithStats(ROImap, connectivity=4)
    largestLabel = 1 + np.argmax(stats[1:, cv2.CC_STAT_AREA])
    ROImap[labels != largestLabel] = 0
    #...
    return roi
```

5.9. kódrészlet: Leszakadt területek eltávolítása részlet

Az 5.9. kódrészletben a `cv2.connectedComponentsWithStats` függvénnyel végzek egy bináris címkézést a `ROImap` nevű bináris képen, ami a szétválasztás művelet eredményéből lett előállítva, amin minden 1 értékű képpont egy kiválasztott területet jelöl, hiszen minden kiválasztott terület egyforma méretű, mert kizárólag a 3. szintről választ az algoritmus, így könnyű volt előállítani. Következő két soron az látszik, hogy csak a legnagyobb összefüggő területet tartom meg. Majd az utána egy ciklus segítségével a `roi` nevű listában rögzítem a megmaradt képpontokat a szétválasztás által visszaadott formátumban, ami a terület bal felső (x, y) koordinátája, illetve a terület szélessége és magassága.

Következő lépés a magpont kiválasztás, amit továbbra is a `DivergenceSeedSelector` osztály fog megvalósítani, azzal a különbséggel, hogy csak az optimális küszöbválasztást kell megváltoztatni, amit a `setOptimalThresholdEnhanced` függvény valósít meg (5.10.kódrészlet), illetve a divergencia kiszámolása előtt a hisztogramot simítom az érzékenyebb számolások miatt.

```
def setOptimalThresholdEnhanced(self, div, bin_edges):
    # ...
    peaks, _ = find_peaks(div, prominence=0.1 * np.max(div))
```

```

score = (0.7*np.abs(peaks-globalMaxIdxImg)/len(div)) + 0.3* (1 -
(div[peaks]/np.max(div)))
chosenPeak = peaks[np.argmin(score)] #idx=chosenPeak, tail 5.6.kódrészlet
#...
eps = 0.03 * np.max(div)
for i in range(len(tail) - window):
    if np.mean(abs(tail[i:i+window])) < eps: nearest_zero = i
#...

```

5.10. kódrészlet: Optimális küszöb meghatározása magpontkiválasztáshoz részlet

A 5.10. kódrészletben ismertetett függvény paramétere a divergencia, ahol a `div` lista az értékeket, míg a `bin_edges` az értékekhez tartozó intenzitásokat mutatja. Az eljárás elején kiszámolom a teljes kép hisztogramját, illetve az 5.8 kódrészletben ismertetett `find_peaks` metódussal csúcsokat keresek, majd a 4.fejezetben említett (4.2) képlet alapján számolok minden csúcsra egy büntetőpontot, amit a `score` lista jelöl. Ezen megkeresve a minimum helyét, megkapom a maximális csúcs indexét. A képletben a teljes kép hisztogramjának maximumát a `globalMaxIdxImg` jelöli. Az 5.6. kódrészlethez hasonlóan választom ki a kezdeti 0-hoz közeli alapértelmezett értéket. Ezután egy ablakot végigtolva a `tail` tömbön, ha az ablak abszolútértékének átlaga kellően kicsi, akkor megállok, és az ablak első elemét választom a 0-hoz legközelebbi elemnek. A „kellően kicsi” értéket az `eps` változó jelöli, amit tapasztalati úton a divergencia maximumértékének 3%-ának választottam, illetve a `window` változót ugyanezen indok miatt 3-nak. A függvényből visszatérve, ha az optimálisnak választott küszöb a divergencia legvégén helyezkedik el, és túlságosan közel a választott maximumhoz, akkor valószínűleg rosszul választottam maximumot, így a maximumhelytől minden intenzitás a negatív maximum értéket kapja a kiszámolt divergencián, illetve ha az optimális küszöb a végén helyezkedik el, de nincs közel a maximumhoz, akkor csak az utolsó pár elemet módosítom ugyanazon módon. Majd a módosított divergencián újra számolok optimális küszöbértéket az előbb tárgyalt függvénnyel. Az újraszámoláshoz használt feltételeket tapasztalati úton választottam, tehát ha az utolsó 20 legmagasabb intenzitáson helyezkedik az optimális küszöb, illetve legfeljebb 20 intenzitásegységre helyezkedik a választott maximumhoz képest.

Az algoritmus túl nagy területet vizsgálva képes sok magpontot kiválasztani, így érdemes lehet utólag szűrni őket, amit a `GradientSeedFilter` osztály valósít meg a `filter` metódusával (5.11. kódrészlet).


```
def filter(self, ctx):
    #...
    sobel = np.hypot(gradX, gradY)
    #...
    edgeMask = (sobel > sobelBlur * 1.5).astype(np.uint8)
    edgeMaskDil = cv2.dilate(edgeMask, structElement)
    filtered = seedMask & ~edgeMaskDil
    #...
    return ctx
```

5.11. kódrészlet: Magpont szűrés részlet

Először meghatározom a Sobel-operátorral a kép x és y irányú gradiensét a `cv2.Sobel`, majd az így kapott gradiensek nagyságát az `np.hypot` függvénnyel határozom meg. Ezután azon éleket tartom meg, amelyek az élkép simítottjának másfélszeresénél nagyobbak, amely konstanst tapasztalati úton határoztam meg. Majd a kiválasztott éleken elvégzek egy dilataciót a `cv2.dilate` segítségével. Végezetül azon magpontokat tartom meg, amelyek nem szerepelnek a kapott élképen.

6. Eredmények

Az általam használt adathalmaz a 2020-ban szervezett agytumor szegmentálás kihíváshoz használt adathalmaz (Brain Tumor Segmentation Challenge 2020), röviden BraTS2020 lesz, ami 369 páciensről készült MRI vizsgálat eredményeit tartalmazza [6,7,8,9]. T_1 , súlyozott T_1 , T_2 , FLAIR alapú képeket tartalmaz, ahol mindegyik kép 155 db axiális szeletből áll, és minden szelethez tartozik már a szakorvosok által szegmentált maszk a tumorról, tehát lehetséges ellenőrizni majd a szegmentálás eredményét. Megjelenésben, formában és szövettan tekintetében többségében homogén daganatok szerepelnek a képeken, nevezetesen gliómák, amik FLAIR típusú képeken jól elkülönülnek. Az adatok már előfeldolgozottak, például ugyanarra a felbontásra vannak interpolálva, a koponya eltávolítás is megtörtént.

6.1. Használt metrikák

Magát a magpont kiválasztást, nem igazán lehet értékelni, a különböző cikkek [1,3] se teszik, viszont magát a szegmentálás végeredményét lehet. Ehhez kikell számolni a konfúziós mátrixot, ami a valódi pozitív (TP), valódi negatív (TN), hamis pozitív (FP) és hamis negatív (FN) értékekből áll. A TP és TN jelzi, azt a pixelszámot, amit mi tumornak találtam az valóban tumorhoz tartozik, amit nem rendeltem hozzá az valóban nem tartozik hozzá. A FP és FN értékek pedig a hibásan besorolt értékeket jelzik, hogy amit tumorhoz soroltam az valójában nem hozzá tartozik és fordítva, amit nem soroltam hozzá az valójában hozzá tartozik.

Ezen számokból számos metrikát elő lehet állítani, amit a feldolgozott cikkek is tárgyalnak. [1,3] Elsősorban a pontosság (accuracy), a helyesen osztályozott pixelek arányát mutatja, ami félrevezető lehet kiegyensúlyozatlan adatoknál. Jelen esetben, ha túl kicsi tumor, például 5%-a a képnek és a maradék háttér, és nem találok el a tumort, hanem mondjuk a háttérből pár pixelt jelöltem ki szegmentált területnek, még akkor is 90% felett lenne a pontosság. A Jaccard-index vagy másnéven metszet-unió arány (Intersection over Union, IoU) a szegmentált területek átfedését méri, kihagyja a háttér az összehasonlításból az előző metrikához képest. Használják még objektum detektálásnál a befoglaló téglalapok összehasonlítására. A következő metrika a Dice-együttható, ami két halmaz közötti hasonlóságot méri hasonlóan az előző IoU-hoz, viszont a ténylegesen eltalált értékek duplán számítanak, így kicsit megbocsátóbb pontszám. A specificitás (Sp) értéke magas, ha a nem tumorhoz tartozó területeket jól jelölöm és minimális a hamis pozitívok száma. Ennek a párja a szenzitivitás (Sn), amit a cikk [1] átfedési hányadnak hív (overlap

fraction: OF) ami magas, ha a helyesen tumorhoz soroltak száma magas és minimális a hamis negatívok száma. A többlethányad (extra fraction, EF) egy nem szokványos mérőszám, ami azt jelöli mennyi „hamis tumor” van jelölve a valódi tumorhoz képest, azaz az FP érték osztva a valódi tumor területtel (TP+FN), tehát minél kisebb annál jobb. A legutoljára említett EF és OF helyett érdemesebb lehet Fals pozitív rátát (FPR) és Fals negatív rátát (FNR) nézni, ami azt mondja meg, hogy ha FPR magas és Sp alacsony akkor túlszegmentálás történt, hiszen hamisan tumorhoz soroltuk, viszont háttér, míg a FNR és Sn esetén az ellenkezője igaz, vagyis alulszegmentálás történt.

6.2. Blokk- és intenzitásalapú módszer és módosításának összehasonlítása

Az eredeti módszert hasonlítom össze annak továbbfejlesztésével. Először a 3. fejezetben tárgyalt módszert és módosítását tárgyalom. Mivel továbbfejlesztésnek a mozgóablak-módszert ajánlottam, annak is 4 különböző ablak rangsorolási stratégiát, majd az ablakokból 2 magpont kiválasztási stratégiát, így először ezt a 8 különböző lehetőséget hasonlítom össze egymással. A 6.1 fejezetben említett metrikákat számoltam és mentettem el csv fájlalba, majd dolgoztam fel őket. Az említett metrikák közül a pontosság végig magas. Az IoU és a Dice-együttható ugyanazt méri csak az utóbbi megengedőbb, én is ezt fogom használni a legfőbb mérőszámnak. Mivel többszázezer szeletnyi adat áll rendelkezésre, így lehet őket különféleképpen csoportosítani, például tumor mérete szerint, amit az `np.quantile` függvény segítségével érek el, ami az adatokból a megadott arányok alapján számít határértékeket, majd ezek segítségével csoportosítom az adatokat.

Paraméterezés	Dice átlag					DS medián				
	tinny	small	medium	large	huge	tinny	small	medium	large	huge
biratu	0.310	0.702	0.804	0.825	0.836	0.103	0.837	0.893	0.897	0.887
blob-center	0.355	0.705	0.782	0.778	0.797	0.171	0.834	0.874	0.860	0.852
blob-max	0.405	0.661	0.681	0.650	0.676	0.399	0.758	0.773	0.723	0.730
max-center	0.305	0.618	0.721	0.753	0.774	0.067	0.789	0.863	0.865	0.866
max-max	0.294	0.459	0.477	0.462	0.490	0.031	0.522	0.517	0.489	0.553
mean-center	0.386	0.731	0.797	0.791	0.805	0.283	0.840	0.877	0.863	0.856
mean-max	0.437	0.686	0.698	0.664	0.684	0.478	0.771	0.782	0.730	0.735
std-center	0.255	0.550	0.668	0.729	0.743	0.057	0.672	0.834	0.859	0.852
std-max	0.305	0.542	0.624	0.642	0.678	0.080	0.651	0.753	0.757	0.793
	tinny	small	medium	large	huge	tinny	small	medium	large	huge
	Tumor méret kategória									

6.1. ábra: Dice-együttható átlag és medián hő térkép, módszer és tumorméret szerint


A 6.1. ábrán az első sor kivételével, ahol az eredeti módszer látható, a többi sorban az előbb említett 8 paraméterezésnek (ponttérkép-középpont) lehet látni a Dice-együtthatójának átlagát, illetve mediánját a tumor mérete szerint csoportosítva. Látható, hogy a medián értékek szinte mindig magasabbak az átlagnál ez azt jelenti, hogy léteznek kiugróan alacsony pontszámmal rendelkező szegmentációk, amik lefele húzzák az átlagot. Az is megfigyelhető, hogy sokkal fontosabb az ablakon belüli magpont kiválasztása, mint maga az ablak választás. Szinte minden esetben az ablak középső pontjának kiválasztásával jobban járok, mintha a legmagasabb intenzitásértékhez tartozó képpontot választanám. Az utóbbi képpont inkább egy szélsőséges érték, amit használva az intenzitás küszöböt használó standard régiónövelés beragad a lokális maximumokba. Ennek ellenére az ábra első oszlopaiban látni, hogy a legkisebb méretű tumorokon mégis a maximum intenzitású pixel a jobb választás lehet, hiszen az ablak közepét választva, az tumoron kívül eshet a finomabb mintavételezés ellenére. A mediánt nézve azt lehet látni, amikor az ablak a maximum intenzitás szerint van pontozva, és az ablak közepe van választva magpontnak (max-center sor), akkor a lehető legmagasabb az elért pontszám a kettő legnagyobb tumor típusra, viszont ugyanennek a módszernek az átlagát nézve legalább 10% a pontszámok esése minden tumorméretre. A magasabb medián pontszámot elérők között már csak a szórás alapú amelyik ennél is instabilabb. A maradék kettő magasabb pontszámú esetén mikor az ablak az átlagintenzitást kapja pontszámának, vagy a folt szerűséget nézi a LoG operátorral, továbbra is az ablak közepét választva magpontnak (mean/blob-center sorok), akkor hasonlóan magas értékeket ad a mediánra, mint az előző esetekben, viszont az átlag pontszáma kevésbé esik vissza az átlagalapúnak, ami így stabilabbnak tűnik.

FPR átlag						FPR medián					
max-center	0.406	0.218	0.162	0.142	0.131	0.220	0.013	0.009	0.010	0.011	
mean-center	0.285	0.091	0.060	0.056	0.049	0.069	0.008	0.006	0.005	0.005	
blob-center	0.243	0.096	0.062	0.054	0.056	0.063	0.008	0.006	0.005	0.005	
biratu	0.397	0.133	0.087	0.079	0.070	0.310	0.012	0.009	0.010	0.012	
FNR átlag						FNR medián					
max-center	0.198	0.186	0.178	0.192	0.203	0.029	0.089	0.099	0.111	0.126	
mean-center	0.126	0.154	0.179	0.226	0.235	0.011	0.094	0.119	0.161	0.181	
blob-center	0.274	0.198	0.201	0.245	0.241	0.055	0.108	0.127	0.172	0.185	
biratu	0.079	0.113	0.121	0.148	0.168	0.000	0.063	0.080	0.099	0.114	
	tiny	small	medium	large	huge	tiny	small	medium	large	huge	

6.2. ábra: FPR és FNR értékek átlag és medián hő térképe, módszer és tumorméret szerint

Illetve az előbb említett legjobb Dice pontszámot (mean/blob-center sor) elérő paraméterezéseknek alacsony a fals pozitív rátájának (FPR) a mediánja (kb. 1%), az átlaga kicsit magasabb 5-10%, ami a 6.2. ábrán látható. Az alacsony FPR arra enged következtetni, hogy nem jellemző a túlszegmentálás, csak a legapróbb tumoroknál, mert ott ugrik meg az FPR (akár 20-30% fölé), illetve a specificitásból (Sp) is a legkisebb tumoroknál veszít az értékéből. Ezzel ellentétben a fals negatív ráta (FNR) mediánja egy kicsit magasabb (10-19%), az átlag szintén ezen a szint környékén van, viszont ott a legnagyobb tumorok esetén 20% fölé lép, így azt a következtetést lehet levonni, hogy a közepes és nagyobb tumorok esetén a hiba alulszegmentálásból ered, amit az Sn értékei is alá támasztanak, ahol szintén a legnagyobb tumorok esetén történik nagyobb esés a pontszámokban. (Az Sp és Sn értékei a melléklet M.3. ábrán láthatóak). A metrikák között említett többlethányad (EF), alátámasztja azt a feltevést, hogy a legkisebb méretű tumorokon túlszegmentálás történik, mert egyedül ott ad magas értéket, viszont a többi tumorméretre, ahol a Dice-együttható magas ott nem (Melléklet M.4. ábra).


A 6.1 ábrán az eredeti cikk [1] elért átlagos Dice-együtthatója a közepes méretű tumorokon hasonló eredményeket ér el, mint az előbb említett továbbfejlesztés legjobb paraméterezései. A közepesnél nagyobb tumorokon 3%-kal magasabb a pontszáma medián és átlag esetén is, míg a közepesnél kisebb tumorokon 1-18%-kal kevesebb a medián értéke, az átlag pedig 3-7%-kal. A legapróbb tumorok kivételével nem jellemző a túlszegmentálás az eredeti módszerre sem, viszont magasabb a FPR száma, mint a módosított két legjobb módszernek (6.2. ábra). A módosított módszereknek végig magasabb a FNR értéke, mint az eredetinek, ezzel jelezve, hogy kicsivel kisebb területet találnak meg a szegmentálás során.



6.3. ábra: Az átlag(bal) és medián(jobb) pontszámok minden szeletre az eredeti és továbbfejlesztett módszer 2 változata szerint

Az összes szeletre nézve az átlagokat a 6.3 ábrán, azt látni, hogy a módosított módszerek átlagosan jobb eredményt érnek el, 1-3%-kal a Dice-együtthatót nézve, illetve kisebb a fals pozitív rátájuk 6%-kal, ami azt jelenti kevésbé szegmentálnak túl adott képeken, viszont jobban alul szegmentál, amit az FNR érték mutat és 5-10%-kal nagyobb. Az érzékenység (Sn) 3-6%-kal csökkent, ami azt mondja meg hogy átlagosan kevesebb tumorterületet találunk, míg a specificitás (Sp) 6%-kal nőtt, ami a helyesen eltalált háttér pixeleket jelöli, így az Sn és Sp nem ütközik a FPR és FNR által mutató értékekkel. A mediánt értékeket vizsgálva FPR és FNR értékek között 1 és 4-6% a különbség. Látszik, hogy pár kiugró eredmény miatt lesz magasabb az átlagban az FPR és FNR, amit a tumorméret szerinti szétbontásnál már lehetett látni. A Dice pontszám értéke a módosított módszereknél az átlagban azért lehet magasabb, mert a nagyobb tumorok esetén csak kicsivel teljesít gyengébben az eredetnél, míg a legkisebbeken jóval magasabb értéket ér el.

Érdekes még, hogy a mozgóablak-módszer milyen képeken teljesít jobban az eredeti módszerhez képest, a tumorméretet leszámítva. Az eredeti módszer kidolgozásából fakadóan nagyon rosszul teljesít, sőt egyáltalán nem talál el semmit, abban az esetben, amikor az agyképen egy olyan alacsony rétegben kell dolgoznia, amiben az agy része is kicsi, mert a morfológia alapú koponya eltávolítás adott esetben képes eltávolítani azokat a minimális részeket, amiken a tumor található. Hasonló eset amikor pici és jól határolt a tumor és 2 ablak közé esik, ezzel nem belelógva az ablak középpontjába, ahonnan a magpontot választja a módszer. A régiónövelés hibájából adódóan rosszul teljesít, amikor a tumor és az agy közötti kontraszt minimális, mivel tumoron belüli magpontokat talál, viszont a régiónövelés túl megy a tumor határain, ami a 6.4. ábrán látható.




6.4. ábra: BraTS20_Training_340_flair 86-os rétegen magpontkijelölés eredeti (bal) mozgóablak-módszer (jobb)

Ezeket a mozgóablak-módszer orvosolja, hiszen nem használja a morfológiai koponyaeltávolítást, és a módszerből adódóan finomabban mintavételez, így magasabb intenzitásokat választva és ezzel elkerülve a régiónövelésből adódó hibát, ami viszont olyan képeken fog megjeleníteni, amikor a

tumor nem feltétlenül elég homogén így túl magas intenzitásokat választ magpontnak és nem tud lejjebb menni, ezáltal beleragadva a tumor legvilágosabb régiójába (Melléklet: M.5. ábra).

6.3. Divergenciaalapú módszer és módosításának összehasonlítása


Következik a divergencián alapuló módszer és módosítottjának összehasonlítása. Jelen esetben nincsenek módszeren belüli érdekes paraméterezések, amiket össze lehet hasonlítani, így közvetlenül a két módszert fogom, először a Dice-együttható alapján összehasonlítani (6.5. ábra).



6.5. ábra: Dice-együttható átlag és medián hőterkép, módszer és tumorméret szerint


A 6.5. ábrán a Dice-együttható átlaga, illetve mediánja látható módszer és tumorméret szerint csoportosítva, ahol az eredeti módszert a „saad”, míg a módosítottat az „enhanced” sor jelöli. Az eredeti módszer nagyon alacsony pontszámokat ér el, amin minden esetben képes volt javítani a módosított módszer. Azt lehet látni az eredeti módszeren, hogy az átlagpontszám jobb a legkisebb és legnagyobb tumorokon, több mint 10%-kal a medián értékénél, ami arra enged következtetni, hogy talált pár olyan tumort, amit kifejezetten jól tudott szegmentálni a többséghez képest. A közepes méretű tumorokon érte el a legjobb eredményét, amiken ráadásul a medián a nagyobb is, mint az átlag 5%-kal. Várható volt, hogy gyengén fog teljesíteni, hiszen az adathalmazból számolt küszöbértékeket kellett számolni a cikk [3] szerint, amelyek egy kis és kevésbé változatos (homogén) adathalmazon határoztak meg. Ezeket még finomhangoltam, hogy jobb eredményt érhessek el, viszont sokkal változatosabb, heterogénebb adathalmazon meglehetősen korlátozottan bizonyult. Továbbá a magpontkiválasztás implementációja viszonylag egyszerű volt (5.6. kódrészlet), mivel a cikk a megvalósítás részleteit nem tárgyalta. A módosított verzió ezen hibákat igyekszik kiküszöbölni, ahol lehet, az adaptív küszöbérték választással, illetve a finomított magpont kiválasztással, ami az eredményeken látszik is. Először is az átlag kizárólag a legkisebb tumorok esetén nagyobb, mint a medián 7%-kal, illetve a többi tumorméreten 10%-kal magasabb a medián, mint az átlag. Lényegében a legkisebb tumorméreten esetenként kiugróan jól

teljesít, míg az összes többin esetenként rosszabb megoldások lefele húzzák az átlagot. Az átlagot és mediánt nézve minden esetben jobban teljesít a módosított verzió. A legrosszabb esetben is a kisméretű tumorokon 8%, ill. 11%-kal jobb, míg a legnagyobb méretű tumorokon 28%, ill. 49.8%-kal jobb eredményt ér el az átlagot és mediánt nézve.



6.6. ábra: FPR és FNR értékek átlag és medián hőterképe, módszer és tumorméret szerint


A 6.6. ábrán láthatóan a fals pozitív ráta alacsony, ami jelen esetben a mediánál a fél százalékot alig éri el. Az átlagot nézve is egyedül a legkisebb tumorokon közelíti meg a 6%-ot. A fals negatív ráta jóval magasabb, ami az eredeti módszer esetén 50+%-ot is elérheti, ami arra enged következtetni, hogy ezen két módszer is kellően alulszegmentál, ami abból adódhat, hogy nagyon magas intenzitásnak választja meg az optimális küszöböt. A módosított változatnak az adaptív küszöbértékekkel és a finomított optimális küszöbválasztással sikerül csökkenteni az alulszegmentálást anélkül, hogy számottevően nőne a FPR. A 6.7. ábrán az összes szeletre kiszámolt átlagot, illetve mediánt lehet látni különböző pontszámokra.



6.7. ábra: Az átlag (bal) és medián (jobb) pontszámok minden szeletre az eredeti és továbbfejlesztett módszer 2 változata szerint

A javított módszer Dice-együtthatója az átlagot vizsgálva 17%-kal, míg a mediánt 30%-kal magasabb az eredetinél, viszont továbbra is csak 56%, ill. 67%-ot éri el, ami azt jelenti, hogy körülbelül a tumorok kicsit több, mint felét találja meg a módszer. Azt is lehet látni, hogy ez a hiba leginkább az alulsegmentálásból ered (FNR), ami 40.7%, ill. 29.4% a javított módszer átlagát és mediánját nézve, viszont így is javítottak az eredeti módszerhez képest 13.7% és 29%-kal. A túlsegmentálás (FPR) egyik módszerre sem jellemző. Az alulsegmentálást az érzékenység (Sn) és specificitás (Sp) is megerősíti, ahol az Sn azt mutatja, hogy a valódi tumorterületek 59.3% és 70.6%-át találja meg, ami 13.7% és 29%-kal jobb, mint az eredeti módszer átlaga és mediánja. Az Sp pedig végig magas, ami a jól eltalált háttérrel jelöli. Az eddigi pontszámokból kiindulva a módosított módszer stabilabban válasz optimális küszöböt, de ennek ellenére mindkettő alulsegmentál, ami annak eredménye, hogy túlságosan magas intenzitáshoz választják az optimális küszöbértéket.

A módosított módszer hiába teljesít jobban minden mutatót nézve, ennek ellenére előfordul az az eset, amikor egy adott képen rosszabbul teljesít, mint az eredeti. Ezen képek jellemzően nagyon zajosak, illetve előfordulhat dupla átmenet, ami alatt azt értem, hogy a tumor 2 vagy több megkülönböztethető intenzitásból áll, általában nem homogén a tumor.



6.8. ábra: BraTS20_Training_67_flair 105. rétegén kijelölt ROI (jobb) és histogramja (bal), ill. divergenciája (közép) a 2 módszer szerint, és a szegmentálás eredménye az agyképen

A 6.8. ábrán azért hibázik az algoritmus, mert rosszul választ optimális küszöböt. Az ábra jobb oldalán látható a vizsgálni kívánt terület és a szegmentált tumor az eredeti fenti, illetve az alsó módosított módszer szerint. Az agyi képektől balra a kijelölt terület histogramja és divergenciája szerepel, az eredeti kék és a továbbfejlesztett verzió narancssárga színnel, illetve a divergencián választott maximumok zöld, míg az algoritmusok által megtalált optimumok pirossal vannak

jelölve. A ROI-n vett zajos hisztogramon végzett simítás több esetben azt eredményezi, hogy a divergencián az átmenet helyén a 0 vagy 0-hoz közeli értékek elvándorolnak, míg az eredeti módszeren a zaj következményeképpen lesz 0 vagy hozzá közeli érték, amit megtalál. Jelenlegi ábrán a két vizsgálni kívánt terület eltérő, ami szintén hozzájárul az előbb említett elvándorláshoz. Az adaptívan meghatározott hiperintenzív tartománynak hatása látszódik az ábrán, hogy a továbbfejlesztett módszer tökéletesen bekeretezi a tumort, ezáltal megnövelve a magasabb intenzitású képpontokat a hisztogramon, emiatt sem talál 0-hoz közeli értéket ott, ahol az eredeti algoritmus, és a simítás csak tovább rontja. Az adathalmaz 9-es sorszámú képének 71. rétegén a két módszer azonos területet talál, ezen esetben a simítás egyedül okozza a rossz küszöb választást. (Melléklet: M.6. ábra) Továbbá rosszul választhat küszöbértéket akkor, ha az ábrán jelölt zöld maximumot rosszul választja az algoritmus abban az esetben, ha a magasabb intenzitáshoz szignifikánsabban magasabb érték tartozik, mint például a 225-ös kép 102. rétegének esetén, ahol a nagy tumort tökéletesen bekeretezi a szétválasztásos módszer, így minimális normális szövet kerül a vizsgálni kívánt területen belülre (Melléklet. M.7. ábra). Abban az esetben amikor jóval jobban teljesít, mint az eredeti módszer, akkor általában homogén és egyszínű tumorokon teszi mindezt.

Összegzés

A diplomamunka végeredményeként elkészült python programozási nyelven egy grafikus felhasználói felület, ahol a felhasználó képes betölteni NIfTI fájlformátumú képeket. Ezen képek rétegein futtatni a megvalósított szegmentáló algoritmusokat, és paramétereiket módosítani. Továbbá a felhasználó képes a szegmentált végeredményt megtekinteni, illetve a fontosabb közbülső lépéseket is.

Az első megvalósított szakirodalombeli módszer Biratu és társai [1] nevéhez fűződik, amely módszer egy blokk-, és intenzitásalapú magpontkiválasztást alkalmazott, előtte egy morfológiai alapú koponyaeltávolítással. A módosított változatban részletesebb mintavételezéssel és különböző pontozási stratégiák szerint választok magpontokat, amik közül az átlagos intenzitás, illetve a LoG operátort használó pontszám adja a legjobb eredményeket. A második módszer Saad és társai [2,3] nevéhez fűződik. Ők egy divergenciaalapú magpont-kiválasztást valósítottak meg a vizsgálni kívánt területen, amit előre beégetett értékek segítségével határoztak meg. A módosított változatban ezen konstans értékeket igyekszem adaptívvá tenni, ahol lehetséges, és a vizsgálni kívánt területről elhagyni a leszakadozó részeket. Továbbá divergencián történő tényleges magpontkiválasztási folyamatot finomítom az eredeti „durva” implementációhoz képest.

Az első módszer [1] és módosítottja hasonló eredményeket értek el. A részletesebb mintavételezés miatt megfigyelhető, hogy a módosított módszer a kis méretű tumorokon jobb eredményeket ér el, míg a nagy heterogén tumorok esetén rosszabbat, mint az eredeti módszer, mivel beragad lokális maximumokba a régió növelés. Megfigyelhető volt, hogy fontosabb szerepe volt az ablakból történő magpontkiválasztásnak, mint maguknak az ablakok kiválasztásának. A második módszer [2,3] esetén a módosított verzió átlaga 17%-kal, míg mediánja 30%-kal magasabb. A legmagasabb növekedést a legnagyobb méretű tumorok mellett tapasztalni. A nagyobb pontszámok eléréshez legnagyobb mértékben a kifinomultabb optimális küszöbérték választás járul hozzá. Ennek ellenére a továbbfejlesztett módszer is alulszegmentál.

Az elért eredmények alapján érdemes lehetne az első módszer esetén (Biratu) az ablakválasztási stratégiák helyett több magpontkiválasztási stratégiát kipróbálni az ablak közepe és maximuma mellett. A második módszer esetén (Saad) érdemesebb lehetne tovább finomítani és stabilizálni az optimális küszöb választást, például nem 0-hoz közeli érték, hanem egy stabil 0 körüli átmenet keresésével.

Irodalomjegyzék

- [1] E. S. Biratu, F. Schwenker, T. G. Debelee, S. R. Kebede, W. G. Negera és H. T. Molla, „Enhanced Region Growing for Brain Tumor MR,” 2021.
- [2] N. M. Saad, S. A. R. A. Bakar, S. Muda és M. Mokji, „Automated segmentation of brain lesion based on diffusion-weighted MRI using a split and merge approach,” 2010.
- [3] N. M. Saad, S. A. R. A. Bakar, A. S. Muda, M. M. Mokji és A. R. Abdullah, „Automated Region Growing for Segmentation of Brain Lesion in Diffusion-weighted MRI,” 2012.
- [4] M. Angulakshmi és G. L. Priya, „Automated Brain Tumour Segmentation Techniques—A Review,” 2017.
- [5] A. Melouah és S. Layachi, „Overview of Automatic Seed Selection Methods for Biomedical Images Segmentation,” 2018.
- [6] „Kaggle,” [Online]. Available: <https://www.kaggle.com/datasets/awsaf49/brats20-dataset-training-validation>. [Hozzáférés dátuma: 1 12 2025].
- [7] B. H. Menze, A. Jakab, S. Bauer, J. Kalpathy-Cramer, K. Farahani és J. Kirby, „The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS),” 2015.
- [8] S. Bakas, H. Akbari, A. Sotiras, M. Bilello, M. Rozycki, J. S. Kirby, J. B. Freymann, K. Farahani és C. Davatzikos, „Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features,” 2017.
- [9] S. Bakas, M. Reyes, A. Jakab, S. Bauer, M. Rempfler és A. Crimi, „Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation, Progression Assessment, and Overall Survival Prediction in the BRATS Challenge,” 2018.
- [10] „Filling holes in an image using OpenCV,” [Online]. Available: <https://learnopencv.com/filling-holes-in-an-image-using-opencv-python-c/>. [Hozzáférés dátuma: 3 10 2025].
- [11] „Understanding the Radiology Report to Diagnose, Treat and Monitor Brain Tumors,” [Online]. Available: <https://www.youtube.com/watch?v=NZKi4O8u6Mc&t=548s>. [Hozzáférés dátuma: 9 10 2025].
- [12] Budai egészségközpont, „Agydaganat,” [Online]. Available: <https://bhc.hu/betegsegek/agydaganat>. [Hozzáférés dátuma: 29 12 2025].
- [13] Yale Medicine, „Primary Brain Tumors,” [Online]. Available: <https://www.yalemedicine.org/conditions/primary-brain-tumors>. [Hozzáférés dátuma: 29 12 2025].
- [14] „Agydaganat,” [Online]. Available: <https://hu.wikipedia.org/wiki/Agydaganat>. [Hozzáférés dátuma: 03 05 2025].
- [15] D. P. Kálmán, Digitális képfeldolgozás (egyetemi jegyzet).
- [16] Taskmonk, „What is NIfTI ?,” [Online]. Available: <https://www.taskmonk.ai/glossary/nifti>. [Hozzáférés dátuma: 9 3 2025].

- [17] n. k. f. Dr. Zsuga Judit és Dr. Reinhardt István, „Agydaganat - Mire számíthat a beteg?,” 30 04 2017. [Online]. Available: <https://www.webbeteg.hu/cikkek/daganat/1241/agydaganat>. [Hozzáférés dátuma: 11 12 2025].
- [18] M. Eörs, „Orvosi képfeldolgozás (egyetemi jegyzet),” 2011. [Online]. Available: <https://www.inf.u-szeged.hu/~mate/medproc/OKF.pdf>. [Hozzáférés dátuma: 5 12 2025].
- [19] Újbuda Medical Center, „Mit kell tudni a kontrasztanyag CT vizsgálatról?,” [Online]. Available: <https://ujbudamedicalcenter.hu/mit-kell-tudni-a-kontrasztanyag-ct-vizsgalatrol/>. [Hozzáférés dátuma: 2025.12.10].
- [20] „Blob detection,” [Online]. Available: https://en.wikipedia.org/wiki/Blob_detection.

Nyilatkozat

Alulírott Varga-Betlehem Ádám programtervező informatikus MSc szakos hallgató, kijelentem, hogy a dolgozatomat a Szegedi Tudományegyetem, Informatikai Intézet Képfeldolgozás és Számítógépes Grafika Tanszékén készítettem, programtervező informatikus MSc diploma megszerzése érdekében.


Kijelentem, hogy a dolgozatot más szakon korábban nem védtem meg, saját munkám eredménye, és csak a hivatkozott forrásokat (szakirodalom, eszközök, stb.) használtam fel.

Tudomásul veszem, hogy diplomamunkámat a Szegedi Tudományegyetem Diplomamunka Repozitóriumban tárolja.


2025. december 18. Varga-Betlehem Ádám

Melléklet

1. A forráskód elérhetősége: <https://github.com/vbadam28/Diplomamunka>
2. Használatra kész adathalmaz elérhetősége, amin a kiértékelés történt:
https://drive.google.com/drive/folders/1EZZz1IwF9RJtUu4z89xD8BfqqUT15NO_?usp=s_haring
3. Mellékelt ábrák:



M.1. ábra: Koponya eltávolítás lépései. Eredeti kép forrása: [1]




M.2. ábra: Koponya eltávolítás lépései. Eredeti kép forrása: [1]

Sp átlag						Sp medián					
max-center	0.594	0.782	0.838	0.858	0.869	0.780	0.987	0.991	0.990	0.989	
mean-center	0.715	0.909	0.940	0.944	0.951	0.931	0.992	0.994	0.995	0.995	
blob-center	0.757	0.904	0.938	0.946	0.944	0.937	0.992	0.994	0.995	0.995	
biratu	0.603	0.867	0.913	0.921	0.930	0.689	0.988	0.991	0.990	0.988	
Sn átlag						Sn medián					
max-center	0.802	0.814	0.822	0.808	0.797	0.971	0.911	0.901	0.889	0.874	
mean-center	0.874	0.846	0.821	0.774	0.765	0.989	0.906	0.881	0.839	0.819	
blob-center	0.726	0.802	0.799	0.755	0.759	0.945	0.892	0.873	0.828	0.815	
biratu	0.921	0.887	0.879	0.852	0.832	1.000	0.937	0.920	0.901	0.886	
	tiny	small	medium	large	huge	tiny	small	medium	large	huge	


M.3. ábra: Sp és Sn átlag, medián hőterkép, módszer és tumorméret szerint

EF átlag						EF medián					
max-center	81.859	3.581	1.307	0.685	0.411	14.935	0.151	0.066	0.046	0.037	
mean-center	70.000	1.496	0.456	0.268	0.153	3.939	0.100	0.041	0.024	0.015	
blob-center	54.717	1.550	0.486	0.251	0.175	4.106	0.102	0.040	0.023	0.014	
biratu	93.173	2.150	0.659	0.369	0.220	16.348	0.158	0.066	0.045	0.037	
	tiny	small	medium	large	huge	tiny	small	medium	large	huge	


M.4. ábra: EF átlag és medián hőterkép, módszer és tumorméret szerint



M.5. ábra: BraTS20_Training_26_flair 62-es rétegen magpontkijelölés eredeti (bal)
mozgóablak-módszer (jobb)



M.6. ábra: BraTS20_Training_9_flair 71. rétegén kijelölt ROI (bal) és hisztogramja (jobb), ill. divergenciája (közép) a 2 módszer szerint, és a szegmentálás eredménye az agyképen



M.7. ábra: BraTS20_Training_225_flair 102. rétegén kijelölt ROI (bal) és hisztogramja (jobb), ill. divergenciája (közép) a 2 módszer szerint, és a szegmentálás eredménye az agyképen